

TRƯỜNG ĐẠI HỌC VĂN LANG
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN MẪU
MÔN: NHẬP MÔN TỐI ƯU HÓA

TỐI ƯU CẤU HÌNH PHÂN CỤM KHÁCH HÀNG
THÍCH ỨNG BẰNG HYBRID-RL

Một ví dụ về tối ưu hóa lồng, đa mục tiêu và tìm kiếm thích ứng trong AI

STT	Họ và tên	MSSV
1	Sinh viên 1	
2	Sinh viên 2	
3	Sinh viên 3 (nếu có)	

Giảng viên:

Lớp học phần:

TÓM TẮT

Đề án nghiên cứu bài toán tối ưu hóa cấu hình phân cụm khách hàng trong môi trường dữ liệu động. Thay vì cố định số cụm, số chiều biểu diễn và phương pháp phân cụm, mô hình Hybrid-RL sử dụng học tăng cường để lựa chọn cấu hình phụ thuộc trạng thái dữ liệu. Dữ liệu đầu vào được ánh xạ vào không gian tiềm ẩn bằng autoencoder; sau đó tác tử RL lựa chọn các biến quyết định gồm số cụm K , latent dimension và clustering type. Hàm phần thưởng kết hợp đồng thời Silhouette Score, Calinski-Harabasz Index và Davies-Bouldin Index nhằm tránh tối ưu quá mức một tiêu chí đơn lẻ.

Bài toán được xem như một tối ưu hóa lồng: vòng trong học tham số mạng autoencoder, vòng ngoài tối ưu cấu hình phân cụm. Khi dữ liệu mới xuất hiện, mô hình cập nhật thông qua fine-tuning và MiniBatchKMeans partial_fit thay vì huấn luyện lại toàn bộ. Báo cáo sử dụng các kết quả thực nghiệm công bố trên bộ dữ liệu Moon Lashes & Brows và Online Retail II để minh họa quy trình đánh giá. Trên Moon Lashes & Brows, Hybrid-RL đạt Silhouette 0.7542, DBI 0.3150, CH 1810.34 và inference runtime 0.0001 s/mẫu. Trên Online Retail II, Silhouette đạt 0.8455. Thực nghiệm drift cho thấy Silhouette giảm khoảng 6.1% dưới nhiều mô phỏng vừa phải.

Từ góc độ môn học, đề án minh họa đầy đủ chuỗi: bài toán thực tế $\rightarrow$ mô hình toán $\rightarrow$ hàm mục tiêu $\rightarrow$ không gian nghiệm $\rightarrow$ thuật toán $\rightarrow$ thực nghiệm $\rightarrow$ đánh giá $\rightarrow$ quyết định. Đây là một ví dụ nâng cao cho việc kết hợp tối ưu hóa đa mục tiêu, hyperparameter optimization, reinforcement learning và thiết kế thực nghiệm trong AI.

Từ khóa: tối ưu hóa đa mục tiêu; Hybrid-RL; học tăng cường; phân cụm sâu; phân cụm gia tăng; concept drift; hyperparameter optimization.

DANH MỤC TỪ VIẾT TẮT

Viết tắt	Tiếng Anh	Tiếng Việt
AE	Autoencoder	Bộ mã hóa tự động
AI	Artificial Intelligence	Trí tuệ nhân tạo
ARI	Adjusted Rand Index	Chỉ số Rand hiệu chỉnh
CH	Calinski-Harabasz Index	Chỉ số Calinski-Harabasz
DBI	Davies-Bouldin Index	Chỉ số Davies-Bouldin
DEC	Deep Embedded Clustering	Phân cụm nhúng sâu
HPO	Hyperparameter Optimization	Tối ưu siêu tham số
IDEC	Improved Deep Embedded Clustering	Phân cụm nhúng sâu cải tiến
MDP	Markov Decision Process	Quá trình quyết định Markov
RL	Reinforcement Learning	Học tăng cường
RFM	Recency-Frequency-Monetary	Gần đây-Tần suất-Giá trị

Nội dung

TÓM TẮT	2
DANH MỤC TỪ VIẾT TẮT	3
NỘI DUNG	Error! Bookmark not defined.
CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI	1
1.1. Bối cảnh nghiên cứu	1
1.2. Bài toán cần giải quyết	1
1.3. Mục tiêu của đề án	2
1.4. Đối tượng và phạm vi	2
1.5. Phương pháp thực hiện	2
1.6. Cấu trúc báo cáo	2
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN	3
2.1. Phân cụm dữ liệu	3
2.2. Deep clustering và học biểu diễn	3
2.3. Autoencoder	3
2.4. Reinforcement Learning và Markov Decision Process	3
2.5. Concept drift và incremental clustering	4
2.6. Các chỉ số đánh giá phân cụm	4
2.7. Các nhóm phương pháp đối sánh	4
2.8. Nhận xét chương	5
CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH HYBRID-RL	6
3.1. Kiến trúc tổng thể	6
3.2. Mô hình tối ưu hóa lồng	6
3.3. Biến quyết định và không gian hành động	6
3.4. Biểu diễn trạng thái	7
3.5. Hàm phần thưởng	7
3.6. Cập nhật Q-learning	7
3.7. Cập nhật gia tăng	7
3.8. Thuật toán tổng quát	7
3.9. Cấu hình thực nghiệm	8
3.10. Độ phức tạp tính toán	8
CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT QUẢ	9
4.1. Bộ dữ liệu	9
4.2. Tiền xử lý dữ liệu	9
4.3. Thiết kế thực nghiệm	9

4.4. Kết quả trên Moon Lashes & Brows	9
4.5. Phân tích runtime	11
4.6. Kết quả trên Online Retail II	11
4.7. Độ bền dưới concept drift.....	12
4.8. Sensitivity Analysis.....	12
4.9. Ablation Study.....	13
4.10. Scalability	14
4.11. Diễn giải cụm khách hàng.....	14
4.12. Thảo luận.....	15
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	16
5.1. Kết luận	16
5.2. Hạn chế.....	16
5.3. Hướng phát triển.....	16
TÀI LIỆU THAM KHẢO.....	17

CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI

1.1. Bối cảnh nghiên cứu

Trong các hệ thống dịch vụ và bán lẻ, dữ liệu hành vi khách hàng được cập nhật liên tục qua các lần đặt lịch, giao dịch, tương tác hoặc phản hồi. Những thay đổi theo mùa vụ, chiến dịch marketing và hành vi tiêu dùng làm phân phối dữ liệu có thể thay đổi theo thời gian. Hiện tượng này được gọi là concept drift và là một trong những nguyên nhân khiến các mô hình học máy tĩnh suy giảm hiệu quả khi vận hành lâu dài [2].

Phân cụm khách hàng là một kỹ thuật thường được sử dụng để phát hiện các nhóm hành vi có đặc trưng tương tự. Tuy nhiên, hiệu quả của phân cụm phụ thuộc mạnh vào biểu diễn dữ liệu, số lượng cụm và thuật toán được sử dụng. Với dữ liệu động, cấu hình tối ưu ở một thời điểm chưa chắc tiếp tục phù hợp khi cấu trúc dữ liệu thay đổi. Các nghiên cứu về clustering gia tăng và data stream clustering đã đề xuất nhiều cơ chế cập nhật mô hình theo dữ liệu mới nhằm hạn chế việc retrain toàn bộ [8]–[10].

Trong bối cảnh đó, Hybrid-RL kết hợp deep representation learning, reinforcement learning và incremental clustering để lựa chọn cấu hình phân cụm một cách thích ứng [1]. Đồ án sử dụng Hybrid-RL làm mô hình chính để khảo sát bài toán tối ưu cấu hình phân cụm khách hàng trong môi trường dữ liệu thay đổi.

1.2. Bài toán cần giải quyết

Bài toán đặt ra là tìm một cấu hình phân cụm vừa tạo được các cụm có mức tách biệt tốt, vừa duy trì tính cô đặc trong cụm và vẫn có khả năng cập nhật khi dữ liệu mới xuất hiện. Nếu lựa chọn K quá nhỏ, các nhóm hành vi khác nhau có thể bị gộp lại. Nếu K quá lớn, cụm dễ bị phân mảnh. Tương tự, số chiều latent quá thấp có thể làm mất thông tin, trong khi latent dimension quá lớn làm tăng độ phức tạp và nguy cơ dư thừa.

Để giải quyết vấn đề, đồ án xác định vector quyết định ở tầng ngoài:

$$\mathbf{x} = (K, d, m)$$

Trong đó K là số cụm, d là số chiều biểu diễn latent và m là phương pháp phân cụm. Tập các cấu hình cho phép được ký hiệu là Ω . Mục tiêu là tìm cấu hình $\mathbf{x}$ tốt nhất trong Ω :

$$\mathbf{x}^* = \underset{\mathbf{x} \in \Omega}{\operatorname{argmax}} J(\mathbf{x})$$

Hàm mục tiêu J được xây dựng từ ba chỉ số chất lượng phân cụm theo [1]:

$$J(\mathbf{x}) = \text{Silhouette}(\mathbf{x}) + \frac{\text{CH}(\mathbf{x})}{500} - \text{DBI}(\mathbf{x})$$

Silhouette và CH được tối đa hóa, còn DBI được tối thiểu hóa. Hệ số 500 được sử dụng để giảm chênh lệch thang đo của CH so với các thành phần còn lại [1].

1.3. Mục tiêu của đề án

- Mô hình hóa bài toán lựa chọn cấu hình phân cụm dưới dạng một bài toán tối ưu hóa đa tiêu chí.
- Xây dựng biểu diễn latent bằng autoencoder để hỗ trợ phân cụm trên dữ liệu hành vi.
- Sử dụng Hybrid-RL để lựa chọn K, latent dimension và clustering method dựa trên trạng thái dữ liệu.
- Kết hợp incremental update để mô hình có thể thích ứng khi dữ liệu mới xuất hiện.
- So sánh kết quả với các phương pháp clustering truyền thống, deep clustering và RL/adaptive clustering.
- Đánh giá mô hình theo chất lượng cụm, runtime, độ bền dưới drift, sensitivity, ablation và scalability.

1.4. Đối tượng và phạm vi

Đối tượng nghiên cứu là bài toán phân cụm dữ liệu hành vi khách hàng dạng bảng. Đề án tập trung vào lựa chọn cấu hình phân cụm, tối ưu biểu diễn và khả năng cập nhật theo batch. Hai bộ dữ liệu được sử dụng gồm Moon Lashes & Brows và Online Retail II như trong [1].

Phạm vi đề án không bao gồm tối ưu trực tiếp doanh thu hoặc retention rate. Các hành động kinh doanh sau phân cụm chỉ được sử dụng để minh họa khả năng diễn giải kết quả. Phần triển khai Bandit, XAI và fairness trong kiến trúc gốc [1] không phải thành phần chính của thực nghiệm trong báo cáo này.

1.5. Phương pháp thực hiện

Quy trình thực hiện gồm bốn giai đoạn. Thứ nhất, dữ liệu được tiền xử lý và chuẩn hóa. Thứ hai, autoencoder được huấn luyện để tạo biểu diễn latent. Thứ ba, tác tử Hybrid-RL lựa chọn cấu hình phân cụm và nhận reward dựa trên các chỉ số nội tại. Thứ tư, khi dữ liệu mới xuất hiện, autoencoder được fine-tuning và MiniBatchKMeans được cập nhật bằng partial_fit. Kết quả được đánh giá bằng các baseline và các thí nghiệm bổ sung như drift test, sensitivity và ablation [1].

1.6. Cấu trúc báo cáo

Báo cáo gồm năm chương. Chương 1 trình bày bối cảnh, bài toán, mục tiêu và phạm vi. Chương 2 trình bày cơ sở lý thuyết và các nghiên cứu liên quan. Chương 3 mô tả mô hình Hybrid-RL và phương pháp tối ưu. Chương 4 trình bày thiết kế thực nghiệm, kết quả và thảo luận. Chương 5 tổng kết kết quả, hạn chế và hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

2.1. Phân cụm dữ liệu

Phân cụm là bài toán chia dữ liệu thành các nhóm sao cho các điểm trong cùng nhóm tương đối giống nhau và các nhóm khác nhau có mức phân tách rõ. KMeans là một trong những thuật toán phổ biến nhất, với mục tiêu tối thiểu hóa tổng bình phương khoảng cách từ mỗi điểm tới centroid của cụm tương ứng:

$$\min_{\{\mu_k\}, \{c_i\}} \sum_{i=1}^n \|z_i - \mu_{c_i}\|_2^2$$

KMeans có ưu điểm đơn giản và hiệu quả nhưng phụ thuộc vào số cụm K, khởi tạo centroid và biểu diễn dữ liệu. Với dữ liệu hành vi có quan hệ phi tuyến, khoảng cách Euclidean trên không gian đặc trưng gốc có thể không phản ánh tốt cấu trúc tiềm ẩn.

2.2. Deep clustering và học biểu diễn

Deep clustering kết hợp học biểu diễn với phân cụm nhằm tạo latent space thuận lợi hơn cho việc tách cụm. DEC sử dụng deep embedding và tối ưu phân phối mục tiêu để cải thiện cấu trúc cụm [3]. IDEC mở rộng DEC bằng cách duy trì thêm reconstruction objective nhằm bảo toàn cấu trúc cục bộ tốt hơn [4]. VaDE kết hợp variational autoencoder với mô hình hỗn hợp Gaussian trong latent space [5].

Các phương pháp trên cho thấy chất lượng phân cụm không chỉ phụ thuộc thuật toán clustering mà còn phụ thuộc cách dữ liệu được biểu diễn. Hybrid-RL kế thừa tư tưởng này bằng cách dùng autoencoder để tạo latent representation trước khi tối ưu cấu hình phân cụm [1].

2.3. Autoencoder

Autoencoder gồm encoder f_θ và decoder g_ψ . Encoder ánh xạ dữ liệu đầu vào x sang latent representation z ; decoder tái tạo dữ liệu từ z :

$$z = f_\theta(x), \quad \hat{x} = g_\psi(z)$$

Trong Hybrid-RL, hàm loss của autoencoder kết hợp reconstruction loss với các thành phần thúc đẩy tính cô đặc và tách biệt của cụm [1]:

$$\mathcal{L}_{AE} = \beta_1 \text{MSE} + \beta_2 \text{KL} + \lambda_1 \mathcal{L}_{\text{compact}} + \lambda_2 \mathcal{L}_{\text{separation}}$$

Cấu hình được mô tả trong [1] sử dụng $\beta_1=1.0$, $\beta_2=0.3$, $\lambda_1=0.15$ và $\lambda_2=0.08$. Adam được sử dụng để tối ưu trọng số mạng.

2.4. Reinforcement Learning và Markov Decision Process

Reinforcement Learning mô tả quá trình một tác tử quan sát trạng thái, lựa chọn hành động, nhận reward và cập nhật chính sách. Bài toán thường được biểu diễn dưới dạng Markov Decision Process:


$$M = (S, A, P, R, \gamma)$$

Trong Hybrid-RL, state mô tả chất lượng clustering hiện tại, action là cấu hình mới và reward phản ánh chất lượng cụm. Việc dùng RL cho clustering đã được nghiên cứu trong Deep Reinforcement Clustering [6]. Một hướng khác kết hợp Q-learning, differential evolution và KMeans cho customer segmentation cũng được trình bày trong [7].

2.5. Concept drift và incremental clustering

Concept drift xảy ra khi phân phối dữ liệu hoặc quan hệ giữa các biến thay đổi theo thời gian [2]. Trong phân cụm dữ liệu dòng, nếu mô hình không cập nhật kịp thời, centroid hoặc cấu trúc cụm có thể trở nên không còn phù hợp. Các nghiên cứu [8]–[10] đề xuất nhiều cơ chế incremental clustering và drift-aware clustering nhằm cập nhật mô hình khi dữ liệu mới xuất hiện.

Hybrid-RL sử dụng dữ liệu ban đầu W1 để huấn luyện representation và policy. Khi dữ liệu W2 xuất hiện theo batch, autoencoder được fine-tuning và MiniBatchKMeans cập nhật centroid bằng `partial_fit` [1].



Hình 2.1. Giao thức W1-W2 và cập nhật gia tăng theo [1].

2.6. Các chỉ số đánh giá phân cụm

Chỉ số	Ý nghĩa	Hướng tốt
Silhouette	Đo mức cô đặc trong cụm và tách biệt giữa các cụm	Càng cao càng tốt
Davies-Bouldin Index (DBI)	Đo mức tương đồng giữa các cụm	Càng thấp càng tốt
Calinski-Harabasz (CH)	Tỷ lệ giữa độ phân tán giữa cụm và trong cụm	Càng cao càng tốt
Adjusted Rand Index (ARI)	Đo độ nhất quán giữa hai phép gán nhãn	Càng cao càng tốt
Runtime	Chi phí thời gian tính toán	Càng thấp càng tốt

2.7. Các nhóm phương pháp đối sánh

Trong [1], Hybrid-RL được so sánh với ba nhóm phương pháp. Nhóm thứ nhất là clustering truyền thống gồm KMeans, MiniBatchKMeans, Birch, Agglomerative, Spectral và GMM. Nhóm thứ

hai là deep clustering gồm DEC [3], IDEC [4] và VaDE [5]. Nhóm thứ ba là các phương pháp có thành phần RL hoặc thích ứng như Deep Reinforcement Clustering [6], Q-learning based clustering [7] và các phương pháp incremental/stream clustering liên quan [8]–[10].

Sự đa dạng của baseline giúp đánh giá đồng thời ba khía cạnh: chất lượng biểu diễn, hiệu quả của chiến lược tìm kiếm cấu hình và khả năng thích ứng khi dữ liệu thay đổi.


2.8. Nhận xét chương

Các nghiên cứu liên quan cho thấy ba vấn đề chính cần được xử lý đồng thời: học biểu diễn phù hợp cho phân cụm, lựa chọn cấu hình hiệu quả và cập nhật mô hình dưới concept drift. Hybrid-RL kết hợp ba hướng này trong một pipeline thống nhất [1]. Chương tiếp theo trình bày chi tiết mô hình tối ưu và thuật toán sử dụng trong đề án.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ MÔ HÌNH HYBRID-RL

3.1. Kiến trúc tổng thể

Hybrid-RL được tổ chức thành ba khối chính: học biểu diễn bằng autoencoder, tối ưu cấu hình bằng reinforcement learning và cập nhật clustering theo dữ liệu mới. Kiến trúc gốc còn có lớp hỗ trợ quyết định với Bandit, XAI và fairness [1]. Trong phạm vi đề án, ba khối đầu được sử dụng để xây dựng và đánh giá mô hình.



Hình 3.1. Kiến trúc Hybrid-RL.

3.2. Mô hình tối ưu hóa lồng

Mô hình có hai tầng tối ưu. Ở tầng trong, tham số θ của autoencoder được tối ưu theo loss biểu diễn. Ở tầng ngoài, cấu hình $x=(K,d,m)$ được tối ưu theo reward clustering:

$$\theta^*(x) = \operatorname{argmin}_{\theta} \mathcal{L}_{AE}(\theta; x)$$

$$x^* = \operatorname{argmax}_x J(\theta^*(x), x)$$

Cấu trúc này cho phép mô hình đồng thời điều chỉnh representation và lựa chọn cấu hình phù hợp. Tuy nhiên, chi phí tính toán cũng tăng vì một evaluation ở tầng ngoài có thể yêu cầu chạy clustering trên latent representation tương ứng.

3.3. Biến quyết định và không gian hành động

Biến	Kiểu	Ý nghĩa	Miền khảo sát
K	Integer	Số cụm	2-7
d	Discrete	Latent dimension	5, 10, 15, 20

Biến	Kiểu	Ý nghĩa	Miền khảo sát
m	Categorical	Clustering method	KMeans hoặc Spectral

Action của tác tử được biểu diễn dưới dạng tổ hợp các quyết định trên. Multi-head Q-network được sử dụng để tách đầu ra theo từng nhóm tham số thay vì mã hóa toàn bộ tổ hợp thành một action duy nhất [1].

3.4. Biểu diễn trạng thái

State được xây dựng từ năm thành phần phản ánh trạng thái clustering hiện tại [1]: khoảng cách trung bình trong cụm, độ lệch chuẩn khoảng cách, inertia, reward ở bước trước và chỉ số ổn định.

$$s_t = [d_{\text{mean}}, d_{\text{std}}, \text{inertia}, r_{t-1}, \text{stability}]^T$$

Việc đưa các chỉ số chất lượng và ổn định vào state giúp policy có thông tin về tình trạng hiện tại trước khi chọn cấu hình tiếp theo.

3.5. Hàm phần thưởng

$$R_t = \text{Silhouette}_t + \frac{\text{CH}_t}{500} - \text{DBI}_t$$

tăng khi Silhouette và CH tăng, đồng thời giảm khi DBI tăng. Đây là một dạng scalarization của bài toán nhiều mục tiêu. Hệ số scaling của CH giữ cho thành phần này không lấn át hoàn toàn các metric còn lại [1].

3.6. Cập nhật Q-learning

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha [r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$$

Mô hình sử dụng epsilon-greedy để cân bằng exploration và exploitation. Theo cấu hình trong [1], epsilon bắt đầu từ 0.9, giảm dần về 0.05 với decay 0.99; discount factor $\gamma=0.98$. Trong quá trình học, tác tử tích lũy thông tin từ các evaluation trước để hướng quá trình tìm kiếm cấu hình.

3.7. Cập nhật gia tăng

Khi batch dữ liệu mới xuất hiện, autoencoder được fine-tuning để cập nhật latent representation. MiniBatchKMeans tiếp tục cập nhật centroid bằng partial_fit. Nhờ đó mô hình không cần retrain toàn bộ pipeline từ đầu [1].

$$C_t = \text{Clustering}(Z_t, C_{t-1})$$

3.8. Thuật toán tổng quát

Bước	Nội dung
1	Tiền xử lý W1 và chuẩn hóa đặc trưng.
2	Pretrain autoencoder và sinh latent representation Z.

Bước	Nội dung
3	Khởi tạo multi-head Q-network.
4	Quan sát state s_t .
5	Chọn action $a_t=(K,d,m)$ theo epsilon-greedy.
6	Thực hiện clustering với cấu hình đã chọn.
7	Tính Silhouette, CH, DBI và reward R_t .
8	Cập nhật Q-network.
9	Lặp đến khi kết thúc số episode/budget.
10	Chọn cấu hình có reward tốt nhất.
11	Với W2: fine-tune AE và cập nhật MiniBatchKMeans.
12	Đánh giá metric, drift robustness và runtime.

3.9. Cấu hình thực nghiệm

Thành phần	Tham số	Giá trị tham khảo
Autoencoder	Kiến trúc	$128 \rightarrow 64 \rightarrow \text{latent_dim}$
Autoencoder	Optimizer	Adam
RL	Episodes	150
RL	γ	0.98
RL	$\epsilon \text{ start} \rightarrow \text{min}$	$0.9 \rightarrow 0.05$
RL	$\epsilon \text{ decay}$	0.99
Incremental clustering	MiniBatchKMeans	partial_fit theo batch
Reward	CH scaling	500

Các thông số trên được lấy từ cấu hình được mô tả trong [1]. Một số thông số chi tiết có thể thay đổi giữa các thí nghiệm; do đó toàn bộ cấu hình cần được lưu cùng log khi tái lập.

3.10. Độ phức tạp tính toán

Chi phí của Hybrid-RL gồm chi phí học representation, chi phí đánh giá các action trong quá trình RL và chi phí clustering. Thành phần incremental clustering gần với $O(nkd)$ đối với MiniBatchKMeans, trong đó n là số mẫu, k là số cụm và d là số chiều latent. Các phương pháp như Agglomerative thường có chi phí tăng nhanh hơn khi n tăng. Thí nghiệm scalability ở Chương 4 dùng runtime theo kích thước dữ liệu để đánh giá xu hướng này [1].

CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT QUẢ

4.1. Bộ dữ liệu

Dataset	Quy mô	Lĩnh vực	Đặc điểm
Moon Lashes & Brows	10,212	Dịch vụ đặt lịch	Dữ liệu hành vi 2021-2025, có drift tự nhiên
Online Retail II	~541,000	Bán lẻ trực tuyến	Dữ liệu giao dịch, RFM, temporal split

Moon Lashes & Brows là dữ liệu doanh nghiệp và không công khai do chứa thông tin nhạy cảm. Online Retail II được sử dụng như một bộ dữ liệu công khai để kiểm tra khả năng tổng quát hóa của mô hình [1].

4.2. Tiền xử lý dữ liệu

Các đặc trưng hành vi được xây dựng từ nhóm thông tin như tần suất đặt lịch, độ gần đây, mức chi tiêu, tỷ lệ hủy và đa dạng dịch vụ. Dữ liệu được chuẩn hóa trước khi đưa vào autoencoder. Phần dữ liệu ban đầu W1 được dùng để học representation và policy; phần dữ liệu tiếp theo W2 được xử lý theo batch để đánh giá khả năng incremental adaptation [1].

4.3. Thiết kế thực nghiệm


Thực nghiệm được thực hiện theo ba nhóm. Nhóm thứ nhất so sánh chất lượng phân cụm giữa Hybrid-RL và các baseline. Nhóm thứ hai kiểm tra độ bền dưới synthetic drift, sensitivity của K và latent dimension, đồng thời thực hiện ablation để đánh giá vai trò của RL và incremental update. Nhóm thứ ba đánh giá runtime và khả năng mở rộng theo số mẫu [1].

Các chỉ số chính gồm Silhouette, DBI, CH và runtime. Đối với các phương pháp có tính ngẫu nhiên, kết quả cần được lặp nhiều lần và lưu seed để giảm ảnh hưởng của một lần chạy đơn lẻ. Các số liệu trong phần này được tổng hợp từ kết quả đã công bố trong [1].


4.4. Kết quả trên Moon Lashes & Brows

Algorithm	Silhouette $\uparrow$	DBI $\downarrow$	CH $\uparrow$	Inference runtime (s) $\downarrow$
KMeans	0.2485	1.1263	159.9326	0.0890
MiniBatchKMeans	0.1819	1.8764	55.3617	0.0575
Birch	0.2270	1.2519	145.9615	0.1280
Agglomerative	0.2153	1.2819	143.8108	0.1803
Spectral	0.2304	1.5458	48.6612	0.0537

Algorithm	Silhouette $\uparrow$	DBI $\downarrow$	CH $\uparrow$	Inference runtime (s) $\downarrow$
GMM	0.2382	1.1981	143.5139	0.3503
VaDE	0.4824	1.2995	404.2984	0.4262
IDEC	0.4030	0.7514	877.7537	0.8713
DEC	0.4937	0.6117	1036.7593	1.1872
Q-DE-KMeans	0.2944	1.0747	143.3902	0.3186
CRL	0.4486	0.6505	693.0562	0.0238
UICluster	0.2221	1.2234	126.2152	0.0181
DynamicSupervised	0.2830	1.0989	140.7828	0.0146
Hybrid-RL	0.7542	0.3150	1810.3384	0.0001




Hình 4.1. So sánh Silhouette trên Moon Lashes & Brows.



Hình 4.2. So sánh DBI trên Moon Lashes & Brows.

Trong tập kết quả được báo cáo, Hybrid-RL đạt Silhouette cao nhất và DBI thấp nhất. CH cũng cao hơn các baseline được liệt kê. Điều này cho thấy cấu hình được policy lựa chọn tạo được sự cân bằng tốt hơn giữa mức cô đặc và tách biệt của cụm trong thiết lập thực nghiệm này [1].

4.5. Phân tích runtime




Hình 4.3. So sánh inference runtime trên Moon Lashes & Brows.

Inference runtime của Hybrid-RL được báo cáo là 0.0001 s/mẫu. Giá trị này là thời gian suy diễn sau khi representation và policy đã được tối ưu offline, không phải tổng thời gian huấn luyện. Theo [1], autoencoder pre-training khoảng 2.14 s, RL optimization 1.87 s và incremental updates 0.38 s; tổng thời gian training khoảng 4.39 s.

4.6. Kết quả trên Online Retail II

Algorithm	Silhouette $\uparrow$	DBI $\downarrow$	CH $\uparrow$	Runtime (s) $\downarrow$
KMeans	0.2108	1.4124	268.5202	0.0719
Birch	0.2980	1.1693	221.3645	0.0713
DEC	0.8380	0.2665	2119.8310	1.4745
IDEC	0.7179	0.4584	1945.6460	1.4925
VaDE	0.5130	1.3047	354.5202	1.0287
Hybrid-RL	0.8455	0.1777	14368.19	0.0002




Hình 4.4. Silhouette trên Online Retail II.

Hybrid-RL đạt Silhouette 0.8455 và DBI 0.1777 trên Online Retail II. DEC đạt Silhouette 0.8380 và DBI 0.2665. Kết quả này cho thấy Hybrid-RL duy trì chất lượng phân cụm cạnh tranh trên bộ dữ liệu công khai, ngoài bộ dữ liệu doanh nghiệp ban đầu [1].

4.7. Độ bền dưới concept drift

Synthetic drift được tạo bằng Gaussian noise với $\sigma=0.03$ và dịch chuyển 5% số feature $\pm 5\%$ so với mean ban đầu. Silhouette giảm từ 0.7341 xuống 0.6891, tương đương khoảng 6.1% [1].




Hình 4.5. Silhouette trước và sau synthetic drift.

Mức suy giảm cho thấy mô hình vẫn duy trì được cấu trúc cụm tương đối ổn định dưới nhiễu vừa phải. Tuy nhiên, synthetic drift chỉ mô phỏng một số dạng thay đổi và chưa đại diện đầy đủ cho mọi dạng concept drift trong thực tế [2].

4.8. Sensitivity Analysis

Sensitivity analysis theo K cho thấy Silhouette đạt khoảng 0.7549 khi K=3, 0.6331 khi K=5 và 0.5257 khi K=7 [1].




Hình 4.6. Độ nhạy của Silhouette theo số cụm K.

Kết quả cho thấy tăng số cụm không đồng nghĩa chất lượng luôn tăng. Khi K quá lớn, dữ liệu có thể bị chia thành các cụm nhỏ và làm giảm độ tách biệt. Đối với latent dimension, [1] cũng báo cáo cấu hình $d=5$ hiệu quả hơn các cấu hình 10 hoặc 20 chiều trong thí nghiệm tương ứng.

4.9. Ablation Study

Variant	Silhouette W1	Silhouette W2	DBI W2	CH W2
AE + KMeans (static)	0.8851	0.8441	0.3878	1009.47
AE + Incremental (no RL)	0.8851	0.7341	0.4060	1016.40
AE + RL (no incremental)	0.8851	0.8441	0.3878	1009.47
Full Hybrid-RL	0.8279	0.7542	0.3150	1810.34




Hình 4.7. Ablation giữa static và dynamic.

Ablation cho thấy các thành phần RL và incremental update đóng vai trò khác nhau trong pipeline. Full Hybrid-RL đạt DBI thấp nhất và CH cao nhất trên W2, trong khi các biến thể bỏ một

thành phần mất một phần khả năng thích ứng. Điều này cho thấy chất lượng tổng thể không đến từ một module riêng lẻ mà từ sự phối hợp giữa representation, search policy và cập nhật gia tăng [1].

4.10. Scalability




Hình 4.8. Runtime theo kích thước dữ liệu.

Ở các mức $n=1,000; 5,000; 10,000$, Hybrid-RL có runtime khoảng 0.0050; 0.0132; 0.0224 s trong thí nghiệm scalability [1]. Agglomerative tăng nhanh hơn theo số mẫu, trong khi Hybrid-RL và DynamicSupervised tăng chậm hơn. Kết quả cho thấy mô hình có xu hướng phù hợp hơn với dữ liệu tăng dần trong phạm vi đã khảo sát.

4.11. Diễn giải cụm khách hàng

Cụm	Đặc trưng nổi bật	Hành động gợi ý
C0	Chi tiêu trung bình 84.02; cancel 1%; hoạt động gần đây	Voucher khuyến khích tăng chi tiêu
C1	Chi tiêu trung bình 112.65; cancel 19%; hoạt động gần đây	Yêu cầu deposit để giảm rủi ro hủy
C2	Chi tiêu trung bình 90.91; cancel 7%; tần suất quay lại thấp	Reminder để tăng tần suất quay lại



Hình 4.9. Average spending của ba cụm khách hàng.

Kết quả phân cụm có thể hỗ trợ xây dựng chính sách chăm sóc khách hàng khác nhau theo từng nhóm. Các nghiên cứu về customer retention kết hợp machine learning và XAI cũng nhấn mạnh nhu cầu chuyển kết quả mô hình thành thông tin hỗ trợ quyết định [11]. Tuy nhiên, các hành động trong bảng chỉ là gợi ý dựa trên đặc trưng cụm; hiệu quả thực tế cần được kiểm chứng bằng thử nghiệm kinh doanh riêng.

4.12. Thảo luận

Kết quả thực nghiệm cho thấy Hybrid-RL đạt chất lượng phân cụm tốt trong hai bộ dữ liệu được khảo sát. Điểm mạnh của mô hình nằm ở khả năng kết hợp học biểu diễn với chiến lược tìm kiếm cấu hình và cập nhật gia tăng. Cấu trúc reward đa tiêu chí giúp tránh phụ thuộc vào một metric duy nhất, nhưng đồng thời tạo ra sự phụ thuộc vào cách scaling các thành phần.

Kết quả drift và ablation cung cấp thêm bằng chứng về khả năng thích ứng. Tuy nhiên, mức drift được mô phỏng vẫn còn đơn giản so với thay đổi phức tạp trong thực tế. Bên cạnh đó, dữ liệu Moon Lashes & Brows thuộc một miền dịch vụ cụ thể và không công khai, vì vậy khả năng tái lập độc lập bị giới hạn.

Về hiệu quả tính toán, inference runtime thấp là lợi thế khi triển khai, nhưng cần tách rõ chi phí offline optimization khỏi thời gian suy diễn. Khi search space mở rộng thêm nhiều hyperparameter, số lượng evaluation và chi phí huấn luyện có thể tăng đáng kể. Đây là một hướng cần tiếp tục tối ưu.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Đồ án đã mô hình hóa bài toán lựa chọn cấu hình phân cụm khách hàng thích ứng dưới dạng tối ưu hóa lồng. Tầng trong sử dụng autoencoder để học latent representation; tầng ngoài sử dụng Hybrid-RL để lựa chọn K, latent dimension và clustering method. Hàm reward kết hợp Silhouette, CH và DBI nhằm cân bằng nhiều tiêu chí chất lượng cụm [1].

Trên Moon Lashes & Brows, Hybrid-RL đạt Silhouette 0.7542, DBI 0.3150 và CH 1810.3384; trên Online Retail II, Silhouette đạt 0.8455 [1]. Mô hình cũng duy trì mức suy giảm Silhouette khoảng 6.1% dưới synthetic drift vừa phải. Sensitivity, ablation và scalability cho thấy cấu hình tối ưu phụ thuộc vào K, latent dimension và sự phối hợp giữa RL với incremental update.

Nhìn chung, Hybrid-RL cho thấy tiềm năng trong các bài toán phân cụm dữ liệu động, đặc biệt khi cần lựa chọn cấu hình theo trạng thái và cập nhật theo batch. Tuy nhiên, kết quả hiện tại chỉ phản ánh các dataset, search space và protocol được khảo sát.

5.2. Hạn chế

- Dữ liệu Moon Lashes & Brows là dữ liệu doanh nghiệp và không công khai, gây khó khăn cho việc tái lập độc lập.
- Hàm reward dựa trên clustering metrics nội tại, chưa tối ưu trực tiếp KPI kinh doanh như retention hoặc revenue uplift.
- Scalarization bằng CH/500 có thể ảnh hưởng đến cấu hình được chọn; cần khảo sát thêm các trọng số hoặc phương pháp Pareto.
- Synthetic drift mới mô phỏng một số dạng thay đổi đơn giản và chưa bao phủ recurring drift hoặc abrupt drift phức tạp.
- Search space hiện chỉ gồm K, latent dimension và clustering method; việc mở rộng search space sẽ làm tăng chi phí.

5.3. Hướng phát triển

- Mở rộng objective sang tối ưu đa mục tiêu theo Pareto thay vì chỉ dùng weighted/scaled sum.
- Bổ sung business KPI vào reward để gắn trực tiếp chất lượng phân cụm với hiệu quả kinh doanh.
- So sánh RL-based search với Random Search, Bayesian/TPE và evolutionary optimization trong cùng evaluation budget.
- Đánh giá mô hình trên nhiều lĩnh vực và nhiều kiểu concept drift hơn.
- Mở rộng sang continual/memory-based learning để xử lý recurring drift.
- Tích hợp fairness và explainability vào quá trình lựa chọn cấu hình và ra quyết định.

TÀI LIỆU THAM KHẢO

- [1] Nguyen, A. T. D., Vo, T., & Hoang, V. T. (2026). Hybrid-RL: An Incremental Deep Clustering Framework with Reinforcement Learning for Adaptive Customer Segmentation. *Computers, Materials & Continua*. <https://doi.org/10.32604/cmc.2026.082845>.
- [2] Xiang, Q., Zi, L., Cong, X., & Wang, Y. (2023). Concept drift adaptation methods under the deep learning framework: a literature review. *Applied Sciences*, 13(11), 6515.
- [3] Xie, J., Girshick, R., & Farhadi, A. (2016). Unsupervised deep embedding for clustering analysis. *ICML*, 478-487.
- [4] Guo, X., Gao, L., Liu, X., & Yin, J. (2017). Improved deep embedded clustering with local structure preservation. *IJCAI*, 1753-1759.
- [5] Jiang, Z., Zheng, Y., Tan, H., Tang, B., & Zhou, H. (2017). Variational Deep Embedding: An Unsupervised and Generative Approach to Clustering. *IJCAI*, 1965-1972.
- [6] Li, P., Gao, J., Zhang, J., Jin, S., & Chen, Z. (2023). Deep Reinforcement Clustering. *IEEE Transactions on Multimedia*, 25, 8183-8193.
- [7] Wang, G. (2025). Customer segmentation in the digital marketing using a Q-learning based differential evolution algorithm integrated with K-means clustering. *PLoS One*, 20(2), e0318519.
- [8] Woodbright, M. D., Rahman, M. A., & Islam, M. Z. (2020). A Novel Incremental Clustering Technique with Concept Drift Detection. *arXiv:2003.13225*.
- [9] Nikpour, S., & Asadi, S. (2022). A dynamic hierarchical incremental learning-based supervised clustering for data stream with considering concept drift. *Journal of Ambient Intelligence and Humanized Computing*, 13(6), 2983-3003.
- [10] Rezaei, Z., & Sajedi, H. (2025). TEDA-driven adaptive stream clustering for concept drift detection. *Data & Knowledge Engineering*, 160, 102484.
- [11] Joy, U. G., Hoque, K. E., Uddin, M. N., Chowdhury, L., & Park, S. B. (2024). A Big Data-Driven Hybrid Model for Enhancing Streaming Service Customer Retention Through Churn Prediction Integrated With Explainable AI. *IEEE Access*, 12, 69130-69150.